PRIZE

Recommender System

- Lim Jungmin

NETFLIX

Netflix Prize

Home

Rules

Leaderboard

Update

Leaderboard

Showing Test Score. Click here to show quiz score

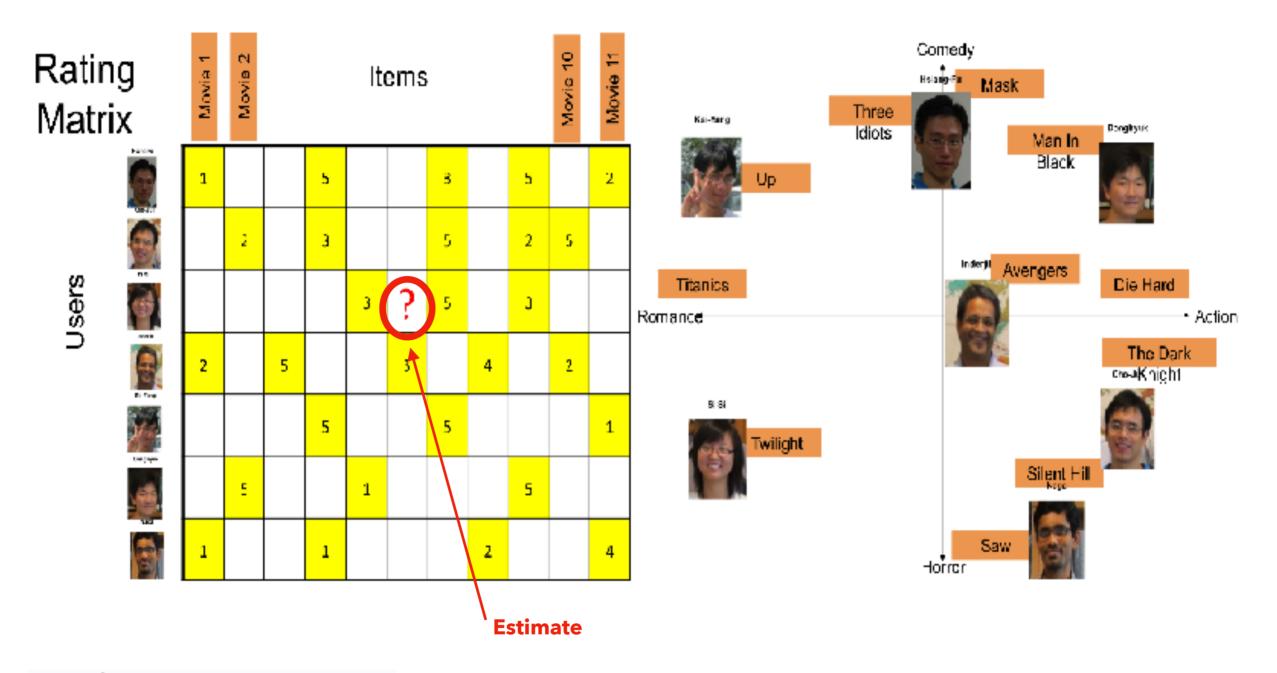
Display top 20 v leaders.

xiangliang

Rank Team Name Best	Test Score %
Grand Prize - RMSE = 0.8567 - Winning Team: B	ellKor's Pragm
1 BellKor's Pragmatic Chaos	0.8567
2 <u>The Ensemble</u>	0.8567
3 Grand Prize Team	0.8582
4 Opera Solutions and Vandelay United	0.8588
5 <u>Vandelay Industries!</u>	0.8591
6 PragmaticTheory	0.8594
7 BellKor in BigChaos	0.8601
8 <u>Dace</u>	0.8612
9 <u>Feeds2</u>	0.8622
10 <u>BiqChaos</u>	0.8623
11 Opera Solutions	0.8623
12 BellKor	0.8624

Progress Prize 2008 - RMSE = 0.8627 - Winning Team: BellKor in

0.8642

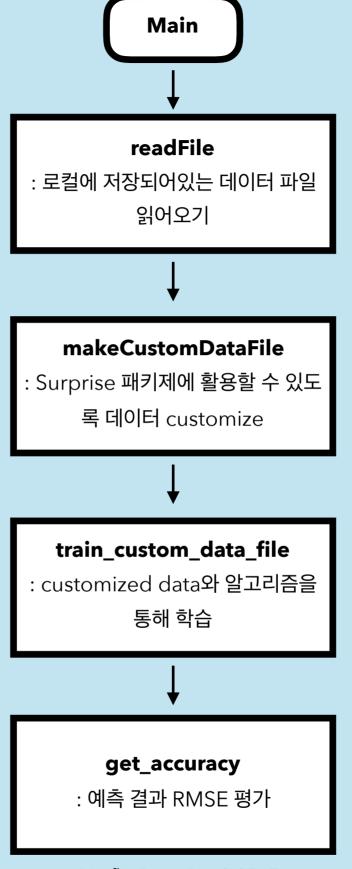


Netflix Recommender System

- 추천 시스템(recommender system)이란 사용자(user)가 상품(item)에 대해 어떻게 평가하는지 예측하는 시스템의 일종이다. Netflix에서 제공한 netflix-prize-data의 경우 17770개의 영화에 대한 고객 2649429명 평점 정보 가 저장되어있다. 위 그림의 '빈칸을 채우는 것'이 이번 프로젝트의 목표이다.
- 추후 공장데이터의 결측치를 수정하는 작업에도 활용될 수 있는 모듈 개발에 활용할 수 있다.

```
# 1. 데이터 파일 읽어오기
start time = time.time()
  data_file = readFile("/Users/limjungmin/
  Netflix Recommender/netflix-prize-data/
  combined data 1.txt")
  run_time = time.time() - start_time
  print ( " Run time for readFile : %.4f (sec)" %
  (run_time) )
  # 2. Surprise 패키지에 활용할 수 있도록 데이터 전처리
 start time = time.time()
  custom data file=makeCustomDataFile(data file)
  run time = time time() - start time
  print ( " Run time for makeCustomDataFile : %.
  4f (sec)" % (run_time) )
  # 3. 사용할 알고리즘(SVD)를 통한 학습 진행
  start time = time.time()
  predictions =
  train_custom_data_file(custom_data_file,
  algo = SVD())
  run_time = time.time() - start_time
  print ( " Run time for train_custom_data_file :
  %.4f (sec)" % (run_time) )
  # 4. 예측 결과를 가지고 RMSE 측정값 구하기
  get_accuracy(predictions)
```

if __name__ == '__main__':



* Netflix Prize #1 : 0.8567 * Surprise 모듈 사용 결과 : 0.9028 낮을 수록 오차 범위가 줄어든다.

```
def readFile(path):
    data_file = open(path)
    return data_file
```

readFile

: 전달된 path를 통해 file을 열고, 해당 데이터 파일을 반환.

Netflix-prize-data INFO

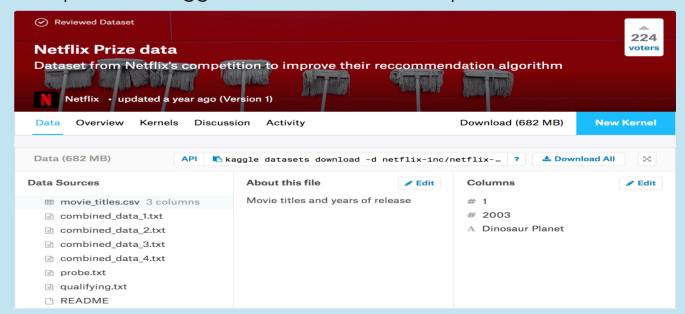
CustomerID, Rating, Date

- MovieIDs range from 1 to 17770 sequentially.
- CustomerIDs range from 1 to 2649429, with gaps. There are 480189 users.
- Ratings are on a five star (integral) scale from 1 to 5.
- Dates have the format YYYY-MM-DD.

데이터(combined_data_1~4.txt 존재, probe set 존재)



* https://www.kaggle.com/netflix-inc/netflix-prize-data



```
def makeCustomDataFile(data file):
# combined data 1.txt에는 4499개의 movieID가 저장.
    custom data file = open("/Users/limjungmin/
    Netflix Recommender/u.data", 'w')
   #cnt = 0 : 디버깅용 Count 계수
   for line in data file:
       if ":" in line:
           movieID = line.split(":")[0]
           #print(movieID)
           #cnt+=1
       else :
           info = line.split(",")
           userID = info[0]
            rating = info[1]
                 date = info[2].split('\n')[0]
           str = userID + ";" + movieID + ";" +
            rating + "\r\n"
           custom_data_file.write(str)
           #if cnt > 50 : break
   print("make Custom Data File Done")
    reader = surprise.Reader(
    line_format='user item rating', sep=';')
    data = surprise.Dataset.load_from_file('/Users/
    limjungmin/Netflix_Recommender/u.data',
    reader=reader)
    df = pd.DataFrame(data.raw ratings,
    columns=["user", "item", "rate", "id"])
    del df["id"]
    print(df.head(10))
    return data
```

makeCustomDataFile

: 기존의 데이터를 surprise 패키지에 사용 가능하도록 전처리.

* https://surprise.readthedocs.io/en/latest/ getting_started.html?highlight=custom#use-a-custom-dataset

```
원본 데이터의 형식
[ movieID: userID, rating, date ]
1:
1488844, 3, 2005-09-06
822109, 5, 2005-05-13
...
```



			<u> </u>	
custom 데이터의 형식		user	item	rate
[userID; movieID; rating]	0	217506	1	2.0
	1	1488844	1	3.0
1488844; 1; 3	2	822109	1	5.0
822109, 1, 5	3	885013	1	4.0
	4	30878	1	4.0
	5	823519	1	3.0
	6	893988	1	3.0
	7	124105	1	4.0
	8	1248029	1	3.0
	9	1842128	1	4.0

```
def train_custom_data_file(data, algo):
    trainset, testset = train_test_split(data,
    test_size=.25)
    algo.fit(trainset)
    predictions = algo.test(testset)
    return predictions
```

```
# 3. 사용할 알고리즘(SVD)를 통한 학습 진행
start_time = time.time()
predictions =
train_custom_data_file(custom_data_file,
algo = SVD())
```

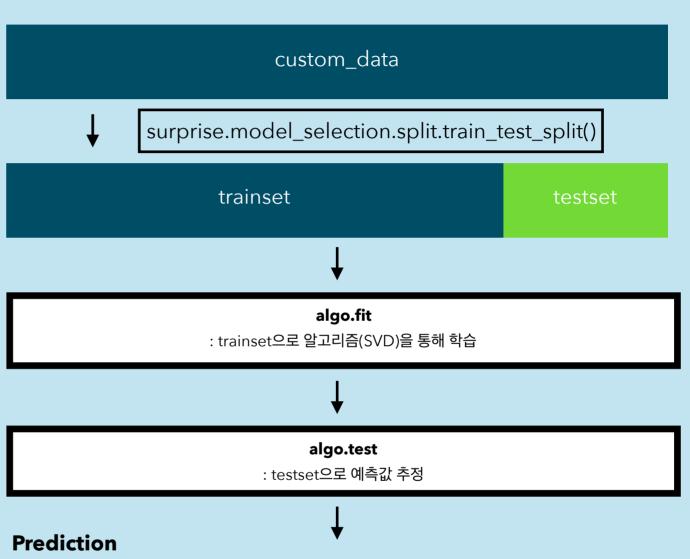
- * 프로그램 Main에서 사용할 알고리즘 전달
- SVD() 알고리즘 사용 방법 https://surprise.readthedocs.io/en/latest/ matrix_factorization.html?highlight=svd
- 사용가능한 알고리즘 목록



https://surprise.readthedocs.io/en/latest/
prediction_algorithms_package.html#

train_custom_data_file : custom 데이터와 사용할 알고리즘을 전달받아 학습 후 예측 결과물 반환

* https://surprise.readthedocs.io/en/latest/model_selection.html? highlight=train_test#surprise.model_selection.split.train_test_split

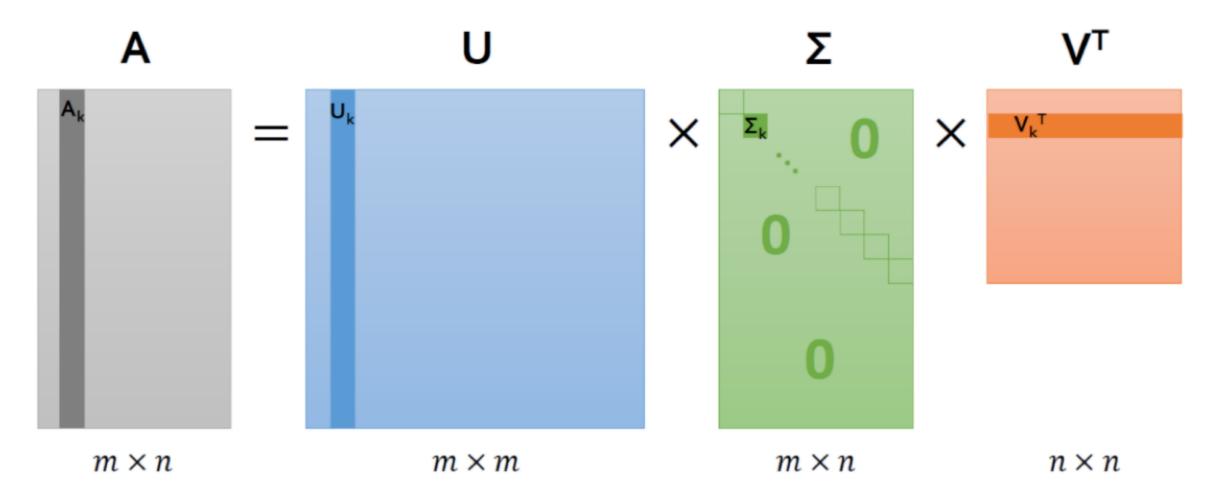


```
predictions[1:10]

[Prediction(uid='1830000', iid='1336', r_ui=3.0, est=2.983732581560073, details={'was_impossible':
False}),
    Prediction(uid='1695685', iid='3893', r_ui=3.0, est=4.006716702498658, details={'was_impossible':
False}),
    Prediction(uid='112076', iid='1608', r_ui=5.0, est=3.804846493184515, details={'was_impossible':
False}),
    Prediction(uid='1699258', iid='312', r_ui=2.0, est=3.2595075184234363, details={'was_impossible':
False}),
```

* uid: userID

r_ui : 사용자가 매긴 평점 est : 알고리즘이 예측한 평점



SVD(Singular Value Decomposition)

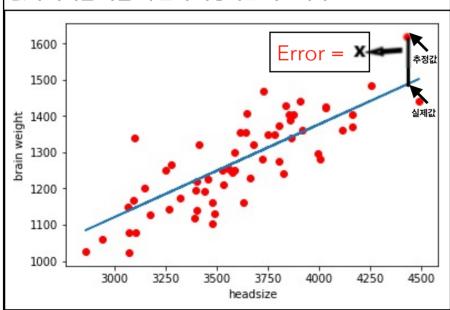
SVD(Singular Value Decomposition)의 추가설명 기재 예정

def get_accuracy(predictions):

return accuracy.rmse(predictions)

* RMSE

: 평균 제곱근 오차(Root Mean Square Error; RMSE) 는 추정 값 또는 모델이 예측한 값과 실제 환경에서 관찰되는 값의 차이를 다룰 때 흔히 사용하는 측도이다.



get_accuracy

: prediction 객체를 전달받아 RMSE 평가 점수를 구한 후 반환한다.

print(accuracy.rmse(predictions))

RMSE: 0.9028 0.9027793490017464

Rank	Team Name	Best Test Score
Grand	<u> Prize</u> - RMSE = 0.8567 - Winning 1	Team: BellKor's Pra
1	BellKor's Pragmatic Chaos	0.8567
2	The Ensemble	0.8567
3	Grand Prize Team	0.8582
4	Opera Solutions and Vandelay United	0.8588
5	Vandelay Industries!	0.8591
6	PragmaticTheory	0.8594
7	BellKor in BiqChaos	0.8601
8	<u>Dace</u>	0.8612
9	Feeds2	0.8622
10	BigChaos	0.8623
11	Opera Solutions	0.8623
12	BellKor	0.8624

Result

Netfilx Prize에서 1위를 차지한 팀의 RMSE 값은 0.8567이며. surprise 모듈을 사용하여 측정한 RMSE 값은 0.9028이다.

* 추정값이 0에 가까울 수록 실제 값 과의 오차가 적음을 나타낸다.

검증 방법의 개요

RMSE : 오차(Error)를 제곱(Square)해서 평균(Mean)한 값의 제곱근(Root)

즉, <u>좌측 그림의 전체 Error</u>와 같이, 예상한 평점값과 실제 평점 결과가 **평균적으로** 얼마만큼 차이나는가를 구하는것으로 이해하면된다.

Neflix Prize의 1위 수치인 0.8567의 경우 평균적으로 **0.8567**, Surprise 모듈의 경우 평균적으로 **0.9026**의 수치 정도로 실제 평점과 차이가 난 다고 이해하면 된다.